



# Sortowania liniowe



# Złożoność sortowania:

sortowanie	złożoność średnia	złożoność pesymistyczna	stabilność
quicksort	O(nlogn)	O(n <sup>2</sup> )	NIE
merge sort	O(nlogn)	O(nlogn)	TAK
heap sort	O(nlogn)	O(nlogn)	NIE
count sort	O(n + k)	O(n + k)	TAK
radix sort	O(d(n+k))	O(d(n+k))	TAK
bucket sort	O(n)	O(n <sup>2</sup> )	TAK



#### Po co to komu?

- szybkie no lepiej niż O(n) się nie da
- **stabilne** jak potrzebujemy stabilności, np. "stackujemy" sortowania (najpierw sortowanie po nazwisku, a potem po imieniu)
- wykorzystują wiedzę o danych kiedy wiemy, że klucze (to, co sortujemy) są z niewielkiego zakresu i/lub mają rozkład jednostajny
- możemy zaprojektować system tak, żeby ich używać decydując się na wybór formatu ID, kluczy itp. możemy z nich zrobić stringi, binary stringi lub integery z ograniczonego zakresu i z rozkładem jednostajnym (podobna długość, zakres znaków) i je później szybko sortować



- wymaganie: zakres wartości w tablicy ograniczony do liczb naturalnych [0, k]
- złożoność: Θ(k+n), dla k=O(n) daje to Θ
   (n) -> k musi być proporcjonalne do rozmiaru tablicy!
- stabilny
- idea: nie porównujemy elementów zliczamy, ile jest elementów o wartości 0, 1, 2, ..., k oraz później wrzucamy je do wynikowej tablicy

```
COUNTING-SORT (A, B, k)

1 let C[0..k] be a new array

2 for i = 0 to k

3 C[i] = 0

4 for j = 1 to A.length

5 C[A[j]] = C[A[j]] + 1

6 \#C[i] now contains the number of elements equal to i.

7 for i = 1 to k

8 C[i] = C[i] + C[i - 1]

9 \#C[i] now contains the number of elements less than or equal to i.

10 for j = A.length downto 1

11 B[C[A[j]]] = A[j]

12 C[A[j]] = C[A[j]] - 1
```



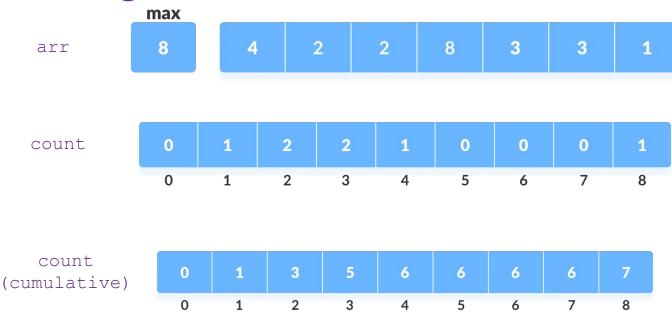
```
A - arr, B - output, C - count
```

- 0. Wyznaczamy k: k = max(arr)
  - Robimy tablicę pomocniczą count z k zerami w niej będziemy zliczać wystąpienia 0 (pod indeksem 0),
     1 (pod indeksem 1), ..., k (pod indeksem k)
- 2. Zliczamy elementy iterujemy po naszej tablicy arr i inkrementujemy odpowiednią wartość w count
- 3. Obliczamy cumulative sum dla każdej komórki w count dodajemy sumę wartości poprzednich
- 4. Robimy tablicę wynikową output tak dużą, jak arr
- 5. Iterujemy od końca (stabilność!) po arr i wykonujemy

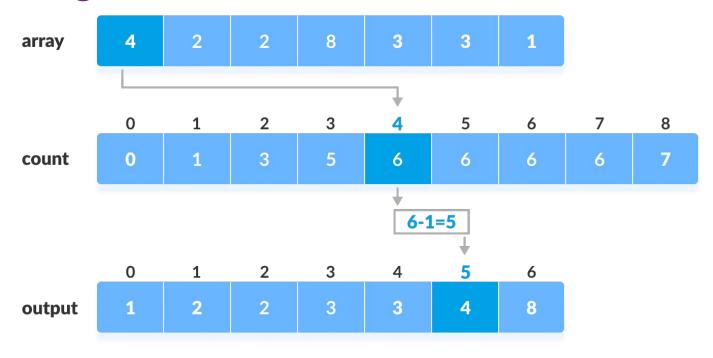
```
output[count[arr[j]] - 1] = arr[j]; count[arr[j]] -= 1
```

- arr[j] wartość elementu w j-tej komórce tablicy wejściowej
- count[arr[j]] tyle "sztuk" elementu o tej wartości nam zostało (dlatego po wstawieniu -1)
- output[count[arr[j]] 1] "wrzucamy" nasz element na to miejsce; -1, bo indeksujemy od zera (Cormen indeksuje od 1)











```
def counting sort(arr):
   n = len(arr)
    k = max(arr)
    output = [0] * n
    counts = [0] * k
    for i in range(n): # count
        count[arr[i]] += 1
    for i in range(k): # cumulative sum
        count[i] += count[i - 1]
    for i in range (n - 1, -1, -1): # place elements in output
        output[count[arr[i]] - 1] = arr[i]
        count[arr[i]] -= 1
    return output
```



#### Radix sort

```
RADIX-SORT(A, d)
```

- 1 for i = 1 to d
- 2 use a stable sort to sort array A on digit i

#### wymagania:

- o dane muszą dać się posortować leksykograficznie, np. integery, stringi
- o dane podobne na pierwszych pozycjach (np. 999991, 999992, 99999)
- najlepiej, żeby były tej samej długości (albo przynajmniej podobnej)

#### złożoność:

- o d liczba pozycji (np. cyfr), k możliwe wartości na pozycjach (np. 10 dla liczb), n liczba elementów do posortowania
- $\circ$  typowo  $\Theta(d(n+k))$ , ogólnie  $O(d^*f(n, k))$  f(n, k) to złożoność sortowania pomocniczego
- idea: sortujemy liczby według kolejnych pozycji, zaczynając od najmniej znaczącej (ostatniej), za pomocą sortowania pomocniczego
- sortowanie pomocnicze stabilne ⇔ radix sort stabilny (lub nie...)



# Radix sort

	329	720	720	329
	457	355	329	355
RADIX-SORT $(A, d)$	657	436	436	436
1 for $i = 1$ to $d$	839	457	839	457
2 use a stable sort to sort array $A$ on digit $i$	436	657	355	657
	720	329	457	720
	355	839	657	839



#### **Bucket sort**

- wymagania:
- o liczby z zakresu [0, 1] ([0, k] z **normalizacją**)
- musimy znać liczbę kubełków n (przynajmniej w przybliżeniu)
- najlepiej rozkład jednostajny
- złożoność:
- $\circ$  O(n) rozkład jednostajny, O(n<sup>2</sup>) tablica z liczbami jednej wartości
- o im bardziej jednostajny rozkład, tym bardziej liniowe
- idea: robimy listę n "kubełków", czyli zakresów długości 1/n, każdy reprezentujemy jako listę, a następnie "wrzucamy" nasze liczby do odpowiednich "kubełków", sortujemy je i przepisujemy do tablicy wynikowej
- normalizacja: na potrzeby liczenia, do którego kubełka powinien trafić element dzielimy go przez największy element z tablicy - wtedy wszystkie będą w zakresie [0, 1]; wrzucamy do niego jednak niezmieniony element!

BUCKET-SORT(A)

- 1 let B[0..n-1] be a new array
- $2 \quad n = A.length$
- 3 **for** i = 0 **to** n 1
- make B[i] an empty list
- 5 for i = 1 to n
- 6 insert A[i] into list B[|nA[i]|]
- 7 **for** i = 0 **to** n 1
- 8 sort list B[i] with insertion sort
  - concatenate the lists  $B[0], B[1], \ldots, B[n-1]$  together in order



#### **Bucket sort**





#### **Bucket sort**

```
def bucket sort(arr, n):
   norm = max(arr)
   buckets = [[] for in range(n)] # list of n empty lists
    for num in arr:
       norm num = num / norm # normalized num
       buck ind = int(n * norm num) # select bucket
       buckets[buck ind].append(num) # add num to bucket
   for i in range(n):
       buckets[i] = sorted(buckets[i])
   output = []
   for i in range(n): # i-th bucket
        for j in range(len(bucket[i])): # j-th element
            output.append(bucket[i][j])
    return output
```



# Zadania



#### Zadanie 1

Mamy dane n punktów (x, y) w okręgu o promieniu k (liczba naturalna), tzn.  $0 \le x^2 + y^2 \le k$ , które są w nim równomiernie rozłożone, tzn. prawdopodobieństwo znalezienia punktu na danym obszarze jest proporcjonalne do pola tego obszaru.

Napisz algorytm, który w czasie  $\Theta(n)$  posortuje punkty po ich odległości do punktu (0, 0), tzn.  $d = \operatorname{sqrt}(x^2 + y^2)$ .



#### Zadanie 2

Mamy daną tablicę stringów, gdzie suma długości wszystkich stringów daje n. Napisz algorytm, który posortuje tę tablicę w czasie O(n).

Można założyć, że stringi składają się wyłącznie z małych liter alfabetu łacińskiego.



#### Zadanie 3

Mamy daną tablicę A z n liczbami naturalnymi. Proszę zaproponować algorytm o złożoności O(n), który stwierdza, czy w tablicy ponad połowa elementów ma jednakową wartość.



#### Zadanie 4

Zaproponuj klasę reprezentującą strukturę danych, która w konstruktorze dostaje tablicę liczb naturalnych długości n o zakresie wartości [0, k]. Ma ona posiadać metodę count\_num\_in\_range(a, b) - ma ona zwracać informację o tym, ile liczb w zakresie [a, b] było w tablicy, ma działać w czasie O(1). Można założyć, że zawsze a >= 1, b <= k.



#### Zadanie 5

Masz daną tablicę zawierającą n (n >= 11) liczb naturalnych w zakresie [0, k]. Zamieniono 10 liczb z tej tablicy na losowe liczby spoza tego zakresu (np. dużo większe lub ujemne). Napisz algorytm, który posortuje tablicę w czasie O(n).



#### Zadanie 6

Dana jest tablica z n liczbami całkowitymi. Zawiera ona bardzo dużo powtórzeń - co więcej, zaledwie O(log(n)) liczb jest unikatowe (reszta to powtórzenia). Napisz algorytm, który w czasie O(n\*log(log(n))) posortuje taką tablicę.



#### Zadanie 7

Dana jest tablica zawierająca n liczb z zakresu  $[0...n^2-1]$ . Napisz algorytm, który posortuje taką tablicę w czasie O(n).



#### Zadanie 8

```
Dana jest klasa : class Node:
```

val = 0

next = None

reprezentująca węzeł jednokierunkowego łańcucha odsyłaczowego, w którym wartości val poszczególnych węzłów zostały wygenerowane zgodnie z rozkładem jednostajnym na przedziale [a, b]. Napisz procedurę sort(first), która sortuje taką listę. Funkcja powinna być jak najszybsza.



#### Zadanie 9

Dane jest słowo będące tablicą n znaków z alfabetu E, o rozmiarze |E|. Dana jest również liczba k. Długość słowa wynosi co najmniej |E|^k. Zaproponuj algorytm, który zwróci najczęściej powtarzający się w tym słowie spójny podciąg o długości k. Algorytm ma działać w czasie O(n), wykorzystywać O(1) pamięci. Ponadto zawartość tablicy po wykonaniu algorytmu powinna pozostać niezmieniona.

Hint: zadanie jest trudne :)



#### Zadanie 10

Dana jest tablica A mająca n liczb naturalnych przyjmujących wartości z zakresu [0...n]. Proszę napisać algorytm znajdujący rozmiar największego podzbioru liczb z A, takiego, że ich GCD jest różny od 1. Algorytm powinien działać jak najszybciej.



#### Zadanie 11

Zaproponuj algorytm, który w czasie O(nlog(n)) posortuje stos o rozmiarze n. Dozwolone jest tylko wykorzystywanie operacji udostępnionych przez interfejs stosu: push(), pop(), top(), isEmpty(), oraz dodatkowych stosów.



#### Zadanie 12

Dany jest zawierający n wierzchołków wielokąt, niekoniecznie wypukły. Jest reprezentowany jako tablica par struktur:

class Point:

X

y

w której (p1, p2) oznacza, że obiekty p1 i p2 klasy Point są połączone odcinkiem. Dany jest również punkt q, leżący poza wielokątem. Zaimplementuj/zaproponuj algorytm, który wyznaczy jak należy poprowadzić półprostą, zaczynającą się w punkcie q, tak aby przecięła jak najwięcej odcinków wielokąta. Uwaga!: zakładamy, że jeśli punkt p jest wspólny dla dwóch odcinków, to prosta przechodząc przez ten punkt przecina oba. Algorytm powinien działać w czasie O(nlog(n)).

